

به نام خدا

پروژه کارشناسی علوم کامپیوتر

دانشگاه شهید مدنی آذربایجان

موضوع

تحلیل احساسات نظرات محصولات دیجی کالا
با استفاده از پردازش زبان طبیعی

استاد راهنما

حسین عباسی مهر

دانشجو

عارف ارومیه ای

بهار و تابستان ۱۴۰۵

فهرست مطالب

۱	مقدمه	۱
۱	تحلیل احساسات (Sentiment Analysis)	۱.۱
۱	اهمیت تحلیل نظرات کاربران	۲.۱
۲	دلیل انتخاب دیجی کالا	۳.۱
۲	هدف پروژه	۴.۱
۳	تعریف مسئله	۲
۳	مسئله‌ای که پروژه حل می‌کند	۱.۲
۳	ورودی و خروجی سیستم	۲.۲
۴	محدودیت‌های پروژه	۳.۲
۴	کاربردهای سیستم	۴.۲
۵	ابزارها و فناوری‌های استفاده شده	۳
۵	زبان برنامه‌نویسی	۱.۳
۵	ابزارهای یادگیری ماشین و پردازش داده	۲.۳
۶	ابزارهای توسعه Backend	۳.۳
۷	ابزارهای توسعه Frontend	۴.۳
۷	معرفی دیتاست‌ها	۴
۸	دیتاست نظرات کاربران	۱.۴
۸	دیتاست محصولات	۲.۴
۹	تعداد رکوردها	۳.۴
۱۰	نحوه برچسب‌گذاری احساسات	۴.۴

۵.۴	دلیل استفاده از نمونه ۱۰۰ تا ۲۰۰ هزار رکورد	۱۰
۵	پیش‌پردازش داده‌ها	۱۱
۱.۵	ادغام دیتاست‌ها (Dataset Merging)	۱۱
۲.۵	حذف داده‌های ناقص و نامعتبر	۱۱
۳.۵	پاک‌سازی متن (Text Cleaning)	۱۱
۴.۵	نرمال‌سازی متن (Normalization)	۱۲
۵.۵	توکن‌سازی (Tokenization)	۱۲
۶.۵	حذف کلمات توقف (Stop Words Removal)	۱۳
۷.۵	آماده‌سازی نهایی متن با Hazm	۱۳
۶	استخراج ویژگی‌ها (Feature Engineering)	۱۴
۱.۶	ویژگی‌های متنی (Text Features)	۱۵
۲.۶	ویژگی‌های امتیازدهی (Rating Features)	۱۵
۳.۶	ویژگی‌های پیشنهاد خرید (Recommendation Features)	۱۵
۴.۶	ویژگی‌های وضعیت خریدار (Buyer Features)	۱۵
۵.۶	ویژگی‌های قیمت (Price Features)	۱۶
۶.۶	ویژگی‌های واکنش کاربران (Reaction Features)	۱۶
۷.۶	ویژگی‌های زمانی (Temporal Features)	۱۶
۷	آموزش مدل‌های یادگیری ماشین	۱۷
۱.۷	مدل Logistic Regression	۱۷
۲.۷	مدل Linear Support Vector Machine (Linear SVM)	۱۸
۳.۷	مدل Random Forest	۱۹
۴.۷	مقایسه اولیه مدل‌ها	۲۰
۸	بهبود مدل (Model Improvement)	۲۱
۱.۸	بهینه‌سازی ویژگی‌های متنی با TF-IDF	۲۱
۲.۸	تنظیم ابرپارامترها با GridSearchCV	۲۲
۳.۸	متعادل‌سازی داده‌ها با SMOTE	۲۳
۴.۸	استفاده از Voting Ensemble	۲۳

۵.۸	انتخاب مدل نهایی	۲۳
۹	نتایج و ارزیابی مدل	۲۵
۱.۹	نتایج دقت (Accuracy)	۲۵
۲.۹	نتایج معیار F۱-Score	۲۵
۳.۹	ماتریس درهم‌ریختگی (Confusion Matrix)	۲۶
۴.۹	تحلیل نتایج	۲۸
۱۰	طراحی و پیاده‌سازی Backend	۲۸
۱.۱۰	استفاده از FastAPI	۲۹
۲.۱۰	ساختار Route ها	۲۹
۳.۱۰	پایگاه داده	۲۹
۴.۱۰	فرآیند پیش‌بینی احساسات (Prediction Flow)	۳۰
۵.۱۰	مدیریت تاریخچه تحلیل‌ها	۳۰
۶.۱۰	خلاصه‌سازی نظرات محصولات (Product Summary)	۳۱
۱۱	طراحی و پیاده‌سازی Frontend	۳۲
۱.۱۱	معماری Frontend	۳۳
۲.۱۱	صفحات سیستم	۳۳
۳.۱۱	ارتباط با Backend	۳۹
۴.۱۱	مدیریت وضعیت برنامه (State Management)	۳۹
۵.۱۱	طراحی رابط کاربری	۴۰
۱۲	پیشنهادهای آینده و دسترسی به کد منبع و مستندات	۴۰
۱.۱۲	پیشنهادهای برای توسعه آینده	۴۰
۲.۱۲	دسترسی به کد منبع و مستندات	۴۱

فهرست تصاویر

۱	فرآیند آماده‌سازی داده‌های متنی پیش از آموزش مدل	۱۴
۲	مقایسه دقت مدل‌ها یادگیری ماشین در تست و یادگیری	۲۱
۳	آمار کلی روش‌های بهبود مدل	۲۴
۴	ماتریس درهم‌ریختگی مدل نهایی (LinearSVC)	۲۷
۵	معماری بخش Backend و جریان پردازش درخواست‌ها	۳۲
۶	صفحه اصلی وب اپلیکیشن	۳۴
۷	صفحه تحلیل احساسات (مثبت)	۳۵
۸	صفحه تحلیل احساسات (منفی)	۳۵
۹	صفحه تحلیل احساسات (خنثی)	۳۶
۱۰	صفحه جستجوی محصولات	۳۷
۱۱	صفحه جزئیات محصول	۳۸
۱۲	مستندات سرویس‌ها	۴۱

فهرست جداول

۱	آمار تقریبی دیتاست‌های مورد استفاده	۹
۲	دسته‌بندی ویژگی‌های استخراج شده	۱۷
۳	مقایسه دقت مدل‌های یادگیری ماشین	۲۰
۴	مقایسه روش‌های بهبود مدل	۲۴
۵	مقایسه روش‌های مختلف بر اساس معیار $F1$ Macro	۲۶

گزارش کار پروژه

۱ مقدمه

۱.۱ تحلیل احساسات (Sentiment Analysis)

در سال‌های اخیر، با گسترش اینترنت و توسعه تجارت الکترونیک، حجم عظیمی از داده‌های متنی توسط کاربران در فضای وب تولید شده است. بخش قابل توجهی از این داده‌ها شامل نظرات، پیشنهادات، انتقادات و تجربیات کاربران درباره محصولات و خدمات مختلف است. یکی از مهم‌ترین شاخه‌های پردازش زبان طبیعی (Natural Language Processing)، تحلیل احساسات است؛ که به فرآیند شناسایی و طبقه‌بندی احساس موجود در یک متن گفته می‌شود و هدف آن تعیین نگرش نویسنده نسبت به یک موضوع، محصول یا خدمت است. در ساده‌ترین حالت، خروجی این فرآیند شامل سه دسته احساس مثبت، منفی و خنثی خواهد بود. امروزه تحلیل احساسات در حوزه‌های مختلفی از جمله تجارت الکترونیک، شبکه‌های اجتماعی، بازاریابی دیجیتال، سیستم‌های پیشنهاددهنده و تحلیل بازخورد مشتریان کاربرد گسترده‌ای پیدا کرده است و نقش مهمی در استخراج دانش از داده‌های متنی ایفا می‌کند.

۲.۱ اهمیت تحلیل نظرات کاربران

نظرات کاربران یکی از مهم‌ترین منابع اطلاعاتی برای ارزیابی کیفیت محصولات و خدمات محسوب می‌شوند. کاربران معمولاً پس از خرید، تجربه واقعی خود را در قالب متن، امتیازدهی و پیشنهاد یا عدم پیشنهاد محصول ثبت می‌کنند. این اطلاعات می‌تواند دیدگاه جامعی درباره نقاط قوت و ضعف یک محصول در اختیار خریداران آینده و همچنین تولیدکنندگان قرار دهد. با توجه به حجم بسیار زیاد این نظرات، بررسی دستی آن‌ها عملاً امکان‌پذیر نیست؛ بنابراین استفاده از روش‌های خودکار مبتنی

بر یادگیری ماشین و پردازش زبان طبیعی به کسب و کارها کمک می‌کند تا در مدت زمان کوتاهی حجم عظیمی از داده‌های متنی را تحلیل کرده و اطلاعات ارزشمندی برای تصمیم‌گیری، بهبود کیفیت محصولات و افزایش رضایت مشتریان کسب کنند.

۳.۱ دلیل انتخاب دیجی‌کالا

در این پروژه، داده‌های فروشگاه اینترنتی دیجی‌کالا به عنوان منبع اصلی اطلاعات انتخاب شده‌اند. دیجی‌کالا یکی از بزرگ‌ترین فروشگاه‌های اینترنتی ایران است که میلیون‌ها کاربر فعال داشته و روزانه تعداد زیادی نظر درباره محصولات مختلف در آن ثبت می‌شود. این مجموعه داده علاوه بر متن نظرات، اطلاعات ارزشمند دیگری نظیر امتیاز کاربران، وضعیت پیشنهاد خرید، تعداد لایک و دیسلایک، اطلاعات محصول، برند، قیمت و سایر مشخصات را نیز در اختیار قرار می‌دهد. تنوع بالای محصولات، حجم زیاد داده‌ها و فارسی بودن متون، این مجموعه را به گزینه‌ای مناسب برای طراحی و ارزیابی یک سامانه تحلیل احساسات زبان فارسی تبدیل کرده است.

۴.۱ هدف پروژه

هدف اصلی این پروژه، طراحی و پیاده‌سازی یک سامانه جامع تحلیل احساسات برای نظرات فارسی کاربران دیجی‌کالا است که بتواند با استفاده از تکنیک‌های پردازش زبان طبیعی و الگوریتم‌های یادگیری ماشین، احساس هر نظر را به صورت خودکار در یکی از سه دسته مثبت، منفی یا خنثی طبقه‌بندی کند. برای تحقق این هدف، ابتدا داده‌های مربوط به محصولات و نظرات کاربران جمع‌آوری و پیش‌پردازش شده‌اند، سپس ویژگی‌های مناسب از داده‌ها استخراج و چندین مدل یادگیری ماشین آموزش و ارزیابی شده‌اند تا بهترین مدل انتخاب شود. علاوه بر بخش هوش مصنوعی، یک سامانه نرم‌افزاری کامل شامل Backend مبتنی بر FastAPI، پایگاه داده SQLite و رابط کاربری تحت وب (Frontend) نیز توسعه یافته است تا کاربران بتوانند به صورت تعاملی نظرات را تحلیل کرده، نتایج را مشاهده کنند، تاریخچه تحلیل‌ها را مدیریت نمایند و اطلاعات تحلیلی مربوط به محصولات را دریافت کنند. در نتیجه، این پروژه یک سامانه End-to-End را از مرحله آماده‌سازی داده‌ها تا ارائه سرویس و نمایش نتایج به کاربران پیاده‌سازی می‌کند و قابلیت توسعه برای استفاده در مقیاس‌های بزرگ‌تر را نیز داراست.

۲ تعریف مسئله

۱.۲ مسئله‌ای که پروژه حل می‌کند

با رشد روزافزون فروشگاه‌های اینترنتی، تعداد نظرات ثبت‌شده توسط کاربران درباره محصولات نیز به شکل قابل توجهی افزایش یافته است. این نظرات حاوی اطلاعات ارزشمندی درباره کیفیت محصولات، میزان رضایت مشتریان، نقاط قوت و نقاط ضعف آن‌ها هستند. با این حال، حجم بالای داده‌های متنی باعث می‌شود بررسی و تحلیل دستی آن‌ها بسیار زمان‌بر، پرهزینه و در بسیاری از موارد غیرممکن باشد. از سوی دیگر، تصمیم‌گیری تنها بر اساس امتیاز عددی محصولات نمی‌تواند تصویر کاملی از تجربه کاربران ارائه دهد؛ زیرا ممکن است یک محصول امتیاز بالایی داشته باشد، اما کاربران در نظرات خود به مشکلات خاصی مانند کیفیت ساخت، عملکرد یا خدمات پس از فروش اشاره کرده باشند. هدف اصلی این پروژه، ارائه یک راهکار هوشمند برای تحلیل خودکار نظرات فارسی کاربران دیجی‌کالا است.

۲.۲ ورودی و خروجی سیستم

ورودی اصلی سیستم، متن نظرات کاربران به زبان فارسی است که می‌تواند به صورت یک نظر یا مجموعه‌ای از چندین نظر به سامانه ارسال شود. علاوه بر داده‌های متنی، در مرحله آموزش مدل از اطلاعات تکمیلی موجود در مجموعه داده نظیر امتیاز محصول، وضعیت پیشنهاد خرید، وضعیت خریدار، تعداد واکنش‌های کاربران، اطلاعات قیمتی و مشخصات محصولات نیز برای استخراج ویژگی‌های مؤثر استفاده شده است.

پس از پردازش متن و اعمال مراحل پیش‌پردازش، مدل آموزش‌دیده احساس هر نظر را پیش‌بینی می‌کند. خروجی سیستم شامل برجسب احساس (مثبت، منفی یا خنثی)، میزان اطمینان مدل نسبت به پیش‌بینی انجام‌شده (Confidence Score) و متن پیش‌پردازش‌شده است. همچنین در بخش جزئیات محصولات، سامانه قادر است خلاصه‌ای از نظرات کاربران، تعداد نظرات هر دسته احساسی و درصد توزیع احساسات مربوط به یک محصول را نیز ارائه دهد.

۳.۲ محدودیت‌های پروژه

با وجود عملکرد مطلوب سامانه، این پروژه با محدودیت‌هایی نیز همراه است. یکی از مهم‌ترین محدودیت‌ها، حجم بسیار زیاد مجموعه داده است. از آنجا که دیتاست اصلی شامل حدود شش میلیون نظر کاربران و بیش از یک میلیون اطلاعات محصول است، آموزش مدل روی کل داده‌ها به منابع پردازشی و حافظه بسیار بالایی نیاز دارد. به همین دلیل، در این پروژه از نمونه‌ای شامل حدود ۱۰۰ تا ۲۰۰ هزار رکورد برای آموزش و ارزیابی مدل استفاده شده است.

از سوی دیگر، زبان فارسی دارای ویژگی‌هایی مانند تنوع نگارشی، استفاده از اصطلاحات محاوره‌ای، غلط‌های املایی، شکل‌های مختلف نوشتاری و ابهام‌های معنایی است که فرآیند تحلیل احساسات را با چالش مواجه می‌کند. همچنین، تشخیص دقیق نظرات خنثی نسبت به نظرات مثبت و منفی دشوارتر بوده و این موضوع بر عملکرد مدل تأثیرگذار است. علاوه بر این، مدل پیاده‌سازی شده از الگوریتم‌های کلاسیک یادگیری ماشین استفاده می‌کند و هنوز از مدل‌های عمیق مبتنی بر ترنسفورمر مانند ParsBERT بهره نمی‌برد که می‌تواند در آینده موجب بهبود دقت سیستم شود.

۴.۲ کاربردهای سیستم

سامانه توسعه‌یافته می‌تواند در حوزه‌های مختلف تجارت الکترونیک و تحلیل داده‌های متنی مورد استفاده قرار گیرد. فروشگاه‌های اینترنتی قادر خواهند بود با استفاده از این سیستم، میزان رضایت مشتریان از محصولات مختلف را به‌صورت خودکار ارزیابی کرده و نقاط قوت و ضعف محصولات را شناسایی کنند. همچنین تولیدکنندگان و فروشندگان می‌توانند با تحلیل بازخورد مشتریان، کیفیت محصولات و خدمات خود را بهبود دهند.

از سوی دیگر، کاربران نیز می‌توانند پیش از خرید یک محصول، به‌جای مطالعه تعداد زیادی نظر، خلاصه‌ای از دیدگاه سایر خریداران و توزیع احساسات ثبت‌شده را مشاهده کرده و تصمیم آگاهانه‌تری اتخاذ کنند. علاوه بر این، معماری ماژولار پروژه و ارائه سرویس‌های API REST باعث شده است که این سامانه قابلیت استفاده در سایر نرم‌افزارها، وبسایت‌ها و سیستم‌های هوشمند را نیز داشته باشد و در آینده بتوان آن را با مدل‌های پیشرفته‌تر، سیستم‌های پیشنهاددهنده محصولات و سایر کاربردهای مبتنی بر هوش مصنوعی توسعه داد.

۳ ابزارها و فناوری‌های استفاده‌شده

در این پروژه، از مجموعه‌ای از ابزارها و فناوری‌های متن‌باز برای پیاده‌سازی بخش‌های مختلف سیستم شامل پردازش داده، یادگیری ماشین، توسعه Backend، طراحی Frontend و مدیریت پایگاه داده استفاده شده است. انتخاب این ابزارها با هدف افزایش کارایی، توسعه‌پذیری و سهولت نگهداری سامانه انجام شده است. در ادامه به معرفی و توضیحی کوتاه در موردشان می‌پردازیم.

۱.۳ زبان برنامه‌نویسی

Python به‌عنوان هسته اصلی پروژه دارای سادگی، جامعه کاربری گسترده و وجود کتابخانه‌های قدرتمند در حوزه علم داده، یادگیری ماشین و توسعه وب است که این زبان را به یکی از بهترین گزینه‌ها برای پروژه‌های هوش مصنوعی تبدیل کرده است. تمامی مراحل پردازش داده، آموزش مدل، توسعه API و ارتباط با پایگاه داده در این پروژه با استفاده از پایتون انجام شده است.

TypeScript از این زبان برای توسعه رابط کاربری پروژه استفاده شده است. زبان تایپ اسکریپت به دلیل مدیریت کامل انواع دیتا تایپ‌ها گزینه بسیار مناسب‌تری نسبت به جاوااسکریپت برای ارتباط با API ها می‌باشد.

۲.۳ ابزارهای یادگیری ماشین و پردازش داده

- Pandas برای بارگذاری، مدیریت، پاک‌سازی، ادغام و تحلیل داده‌های جدولی مورد استفاده قرار گرفته است. بخش عمده عملیات آماده‌سازی داده‌ها و Engineering Feature با استفاده از این کتابخانه انجام شده است.

- NumPy برای انجام محاسبات عددی، عملیات روی آرایه‌ها و افزایش سرعت پردازش داده‌ها مورد استفاده قرار گرفته و پایه بسیاری از محاسبات کتابخانه‌های یادگیری ماشین را تشکیل می‌دهد.

- Hazm یکی از مهم‌ترین کتابخانه‌های پردازش زبان طبیعی فارسی است که در این پروژه برای نرمال‌سازی متن، توکن‌سازی، حذف نویسه‌های اضافی و آماده‌سازی نظرات فارسی پیش از آموزش مدل استفاده شده است.

- Scikit-Learn این کتابخانه اصلی‌ترین ابزار یادگیری ماشین پروژه محسوب می‌شود. الگوریتم‌های طبقه‌بندی، استخراج ویژگی با TF-IDF، تقسیم داده‌ها، ارزیابی مدل، تنظیم ابرپارامترها (GridSearchCV) و سایر مراحل آموزش و ارزیابی مدل با استفاده از این کتابخانه انجام شده‌اند.
- Joblib برای ذخیره و بارگذاری مدل نهایی آموزش‌دیده و بردارساز TF-IDF از این کتابخانه استفاده شده است. این کار موجب می‌شود مدل تنها یک‌بار آموزش داده شده و در زمان اجرای وب سرویس مستقیماً مورد استفاده قرار گیرد.
- Notebook Jupyter فرآیند تحلیل داده‌ها، انجام آزمایش‌های مختلف، آموزش مدل‌ها، مقایسه نتایج و مستندسازی مراحل توسعه در محیط Notebook Jupyter انجام شده است. این محیط امکان اجرای مرحله‌به‌مرحله کد و مشاهده هم‌زمان نتایج را فراهم می‌کند.

۳.۳ ابزارهای توسعه Backend

- FastAPI برای توسعه وب سرویس پروژه از این فریم‌ورک استفاده شده است. این فریم‌ورک به دلیل سرعت بالا، پشتیبانی از برنامه‌نویسی ناهمگام (Asynchronous Programming)، تولید خودکار مستندات API، سادگی در پیاده‌سازی و عملکرد مناسب، انتخاب مناسبی برای ارائه سرویس محسوب می‌شود.
- SQLite به‌منظور ذخیره تاریخچه تحلیل‌ها و اطلاعات مربوط به محصولات، از این پایگاه داده استفاده شده است. سبک بودن، عدم نیاز به نصب جداگانه و سادگی مدیریت از مهم‌ترین دلایل انتخاب این پایگاه داده برای پروژه بوده است.
- SQLAlchemy به‌عنوان لایه ارتباطی بین برنامه و پایگاه داده مورد استفاده قرار گرفته است. این کتابخانه امکان مدیریت داده‌ها از طریق ORM را فراهم کرده و باعث افزایش خوانایی و قابلیت توسعه کد می‌شود.

۴.۳ ابزارهای توسعه Frontend

- React یک کتابخانه متن باز مبتنی بر جاوااسکریپت است که برای طراحی رابط‌های کاربری پویا و تعاملی مورد استفاده قرار می‌گیرد. در این پروژه، React به عنوان هسته اصلی Frontend انتخاب شده است. استفاده از معماری مبتنی بر کامپوننت (Component-Based Architecture) باعث شده بخش‌های مختلف رابط کاربری به صورت مستقل توسعه داده شوند و قابلیت استفاده مجدد از کامپوننت‌ها افزایش یابد.
- CSS Tailwind یک فریم‌ورک CSS مبتنی بر Classes Utility است که امکان طراحی سریع و منعطف رابط کاربری را فراهم می‌کند. در این پروژه، از CSS Tailwind برای طراحی صفحات، ایجاد چیدمان مناسب، پیاده‌سازی طراحی واکنش‌گرا (Responsive) و یکپارچه‌سازی ظاهر بخش‌های مختلف استفاده شده است.
- Zustand یک کتابخانه سبک برای مدیریت وضعیت (State Management) در برنامه‌های React است. در این پروژه، از Zustand برای مدیریت داده‌های مشترک بین صفحات مختلف مانند اطلاعات محصولات، نتایج تحلیل احساسات و وضعیت بارگذاری استفاده شده است.
- Axios یک کتابخانه محبوب برای ارسال درخواست‌های HTTP در برنامه‌های JavaScript و React است. در این پروژه، تمامی ارتباطات میان Frontend و Backend از طریق Axios انجام می‌شود. درخواست‌هایی مانند تحلیل احساسات، جستجوی محصولات، دریافت اطلاعات هر محصول و دریافت خلاصه نظرات با استفاده از این کتابخانه به سرور ارسال می‌شوند.
- smart-persian-tools این پکیج که توسط خودم توسعه داده شده و برای تبدیل ارقام انگلیسی به فارسی در پروژه مورد استفاده قرار گرفته است.

۴ معرفی دیتاست‌ها

یکی از مهم‌ترین بخش‌های هر پروژه یادگیری ماشین، انتخاب دیتاست مناسب است. کیفیت، حجم و تنوع داده‌ها تأثیر مستقیمی بر عملکرد مدل نهایی دارند. در این پروژه، از دو دیتاست مرتبط با فروشگاه اینترنتی دیجی‌کالا استفاده شده است که شامل اطلاعات محصولات و نظرات ثبت‌شده توسط کاربران

می‌باشد. این دو دیتاست پس از انجام عملیات پیش‌پردازش و ادغام، به‌عنوان داده ورودی فرآیند آموزش مدل مورد استفاده قرار گرفته‌اند.

۱.۴ دیتاست نظرات کاربران

دیتاست نظرات شامل حدود ۶ میلیون نظر ثبت‌شده توسط کاربران درباره محصولات مختلف دیجی‌کالا است. هر رکورد بیانگر نظر یک کاربر درباره یک محصول بوده و علاوه بر متن نظر، اطلاعات تکمیلی متعددی نیز در آن وجود دارد. از مهم‌ترین ستون‌های این دیتاست می‌توان به موارد زیر اشاره کرد:

- شناسه محصول (Product ID)

- متن نظر (Comment Body)

- امتیاز ثبت‌شده توسط کاربر (Rating)

- وضعیت پیشنهاد خرید (Recommendation Status)

- وضعیت خریدار (Verified Buyer)

- تعداد لایک و دیسلایک هر نظر

- تاریخ ثبت نظر

وجود این اطلاعات باعث می‌شود علاوه بر متن، بتوان از ویژگی‌های جانبی نیز در فرآیند استخراج ویژگی و آموزش مدل استفاده کرد.

۲.۴ دیتاست محصولات

دومین دیتاست مورد استفاده، شامل اطلاعات بیش از ۱/۲ میلیون محصول موجود در فروشگاه دیجی‌کالا است. این دیتاست اطلاعات عمومی محصولات را در اختیار قرار می‌دهد و برای تکمیل اطلاعات نظرات و استخراج ویژگی‌های بیشتر با دیتاست نظرات ادغام شده است. برخی از مهم‌ترین ستون‌های این دیتاست عبارت‌اند از:

- شناسه محصول

- عنوان محصول
- برند
- دسته‌بندی محصول
- قیمت
- میزان تخفیف
- وضعیت موجودی
- اطلاعات فروشنده

اطلاعات این دیتاست به استخراج ویژگی‌هایی مانند اختلاف قیمت، نرخ تخفیف، میانگین امتیاز محصولات و سایر ویژگی‌های مرتبط کمک می‌کند.

۳.۴ تعداد رکوردها

مشخصات کلی مجموعه داده‌های استفاده‌شده در پروژه در جدول زیر آورده شده است.

جدول ۱: آمار تقریبی دیتاست‌های مورد استفاده

دیتاست	تعداد تقریبی رکورد
نظرات کاربران	حدود ۶,۰۰۰,۰۰۰
اطلاعات محصولات	حدود ۱,۲۰۰,۰۰۰

پس از ادغام این دو مجموعه داده بر اساس شناسه محصول، اطلاعات کامل‌تری برای هر نظر در اختیار مدل قرار گرفت که امکان استخراج ویژگی‌های متنوع‌تر را فراهم کرد.

۴.۴ نحوه برچسب‌گذاری احساسات

از آنجا که دیتاست اولیه دارای برچسب مستقیم احساسات نبود، برچسب‌های موردنیاز برای آموزش مدل به‌صورت خودکار تولید شدند. در این پروژه، امتیاز ثبت‌شده توسط کاربر (Rating) به‌عنوان معیار اصلی تعیین احساس در نظر گرفته شد و در مواردی که اطلاعات مربوط به وضعیت پیشنهاد خرید (Recommendation Status) موجود بود، از آن به‌عنوان معیار تکمیلی برای تعیین دقیق‌تر برچسب استفاده شد.

در نهایت، تمامی نظرات در یکی از سه کلاس زیر قرار گرفتند:

۱. مثبت (Positive): نظراتی که بیانگر رضایت کاربران از محصول هستند.
 ۲. منفی (Negative): نظراتی که نارضایتی یا تجربه نامطلوب کاربران را نشان می‌دهند.
 ۳. خنثی (Neutral): نظراتی که احساس مشخصی نداشته یا ترکیبی از نقاط قوت و ضعف محصول را بیان می‌کنند.
- این روش برچسب‌گذاری باعث شد بدون نیاز به برچسب‌گذاری دستی میلیون‌ها نظر، دیتاست مناسبی برای آموزش مدل یادگیری ماشین ایجاد شود.

۵.۴ دلیل استفاده از نمونه ۱۰۰ تا ۲۰۰ هزار رکورد

اگرچه دیتاست اصلی شامل بیش از شش میلیون نظر کاربران است، اما آموزش مدل روی کل داده‌ها به زمان پردازش بسیار زیاد، حافظه بالا و منابع سخت‌افزاری قدرتمند نیاز دارد. به همین دلیل، در این پروژه از نمونه‌ای شامل ۱۰۰ تا ۲۰۰ هزار رکورد برای توسعه، آزمایش و آموزش مدل استفاده شد. انتخاب این نمونه باعث شد فرآیندهای پیش‌پردازش، استخراج ویژگی، آموزش مدل، تنظیم ابرپارامترها و ارزیابی عملکرد در زمان مناسب انجام شوند و امکان انجام آزمایش‌های متعدد روی مدل‌های مختلف فراهم گردد. همچنین ساختار پیاده‌سازی پروژه به‌گونه‌ای طراحی شده است که در صورت دسترسی به منابع سخت‌افزاری مناسب، بتوان محدودیت تعداد رکوردها را حذف کرده و مدل را روی کل دیتاست آموزش داد.

۵ پیش‌پردازش داده‌ها

یکی از مهم‌ترین مراحل در پروژه‌های پردازش زبان طبیعی، آماده‌سازی و پیش‌پردازش داده‌ها است. کیفیت داده‌های ورودی تأثیر مستقیمی بر عملکرد مدل‌های یادگیری ماشین دارد و هرگونه نویز، داده ناقص یا ناهماهنگی در متن می‌تواند موجب کاهش دقت مدل شود. به همین دلیل، پیش از آغاز فرآیند آموزش، مجموعه‌ای از عملیات پیش‌پردازش بر روی داده‌های خام انجام شد تا داده‌ها به فرمتی استاندارد و مناسب برای مدل‌های یادگیری ماشین تبدیل شوند.

۱.۵ ادغام دیتاست‌ها (Dataset Merging)

در این پروژه از دو دیتاست مجزا شامل اطلاعات محصولات و نظرات کاربران استفاده شد. این دو از طریق شناسه یکتای هر محصول (Product ID) با یکدیگر ادغام شدند تا علاوه بر متن نظرات، اطلاعات مربوط به هر محصول نیز در اختیار مدل قرار گیرد.

۲.۵ حذف داده‌های ناقص و نامعتبر

پس از ادغام داده‌ها، کیفیت اطلاعات بررسی شد. برخی از رکوردها دارای مقادیر خالی یا اطلاعات ناقص بودند؛ برای مثال، تعدادی از نظرات فاقد متن، امتیاز یا شناسه محصول معتبر بودند. این رکوردها به دلیل تأثیر منفی بر فرآیند آموزش مدل از مجموعه داده حذف شدند. همچنین داده‌های تکراری شناسایی و حذف شدند تا از ایجاد سوگیری در فرآیند آموزش جلوگیری شود. این مرحله موجب افزایش کیفیت داده‌ها و کاهش خطاهای احتمالی در مراحل بعدی شد.

۳.۵ پاک‌سازی متن (Text Cleaning)

متن نظرات کاربران معمولاً شامل نویسه‌های اضافی، علائم نگارشی غیرضروری، فاصله‌های نامنظم، ایموجی‌ها، لینک‌ها، اعداد و کاراکترهای خاص است. وجود این موارد معمولاً اطلاعات مفیدی برای تشخیص احساسات فراهم نمی‌کند و تنها باعث افزایش نویز داده‌ها می‌شود. به همین دلیل، در مرحله پاک‌سازی متن، عملیات زیر انجام شد:

- حذف کاراکترهای غیرضروری و علائم نگارشی اضافی

- حذف لینک‌ها و نشانی‌های اینترنتی

- حذف اعداد و نمادهای غیرمفید

- حذف فاصله‌های اضافی

- یکسان‌سازی قالب کلی متن

در نتیجه، متن‌ها به شکل ساده‌تر و یکنواخت‌تری برای پردازش آماده شدند.

۴.۵ نرمال‌سازی متن (Normalization)

یکی از چالش‌های پردازش زبان فارسی، وجود شکل‌های مختلف نگارش یک کلمه است. برای مثال، تفاوت میان حروف «ی» و «ی» یا «ک» و «ک»، استفاده از نیم‌فاصله، کشیدگی حروف و فاصله‌های نامنظم می‌تواند باعث شود یک کلمه در قالب‌های متفاوتی در داده ظاهر شود.

برای رفع این مشکل، از قابلیت Normalizer کتابخانه Hazm استفاده شد. در این مرحله عملیات زیر انجام گرفت:

- یکسان‌سازی حروف فارسی و عربی

- اصلاح فاصله‌ها و نیم‌فاصله‌ها

- حذف کشیدگی حروف

- استانداردسازی قالب نگارش کلمات

نرمال‌سازی باعث کاهش تعداد کلمات تکراری با نگارش متفاوت و افزایش کیفیت استخراج ویژگی‌ها شد.

۵.۵ توکن‌سازی (Tokenization)

پس از نرمال‌سازی، متن هر نظر به واحدهای کوچک‌تر یا توکن تقسیم شد. در این مرحله، هر جمله به مجموعه‌ای از کلمات مستقل تبدیل گردید تا امکان تحلیل آماری و استخراج ویژگی از متن فراهم شود. فرآیند توکن‌سازی نیز با استفاده از ابزارهای ارائه‌شده در کتابخانه Hazm انجام شد که برای ساختار زبان فارسی بهینه شده‌اند.


۶.۵ حذف کلمات توقف (Stop Words Removal)

بخش قابل توجهی از کلمات موجود در متون فارسی مانند «از»، «به»، «در»، «برای»، «که» و «با» نقش معنایی مهمی در تشخیص احساس ندارند و تنها باعث افزایش حجم داده‌ها می‌شوند. این کلمات که با عنوان Stop Words شناخته می‌شوند، در این مرحله از متن حذف شدند. حذف این کلمات موجب کاهش ابعاد فضای ویژگی‌ها، افزایش سرعت آموزش مدل و تمرکز بیشتر الگوریتم بر روی واژگان دارای بار معنایی و احساسی شد.

۷.۵ آماده‌سازی نهایی متن با Hazm

در پایان، تمامی مراحل پیش‌پردازش با استفاده از کتابخانه Hazm در قالب یک تابع واحد بر روی تمامی نظرات اعمال شد. خروجی این مرحله، متنی استاندارد، پاک‌سازی شده و آماده برای استخراج ویژگی با روش TF-IDF و آموزش مدل‌های یادگیری ماشین بود.

استفاده از Hazm به دلیل پشتیبانی مناسب از زبان فارسی، نقش مهمی در افزایش کیفیت داده‌های ورودی و بهبود عملکرد مدل نهایی ایفا کرد. پس از پایان این مرحله، داده‌های آماده‌شده وارد بخش استخراج ویژگی و آموزش مدل شدند.



شکل ۱: فرآیند آماده‌سازی داده‌های متنی پیش از آموزش مدل

۶ استخراج ویژگی‌ها (Feature Engineering)

پس از تکمیل مرحله پیش‌پردازش، داده‌های متنی و اطلاعات جانبی محصولات برای استفاده در الگوریتم‌های یادگیری ماشین به ویژگی‌های قابل پردازش تبدیل شدند. این مرحله که با عنوان استخراج ویژگی شناخته می‌شود، یکی از مهم‌ترین مراحل توسعه مدل‌های یادگیری ماشین است؛ زیرا کیفیت و نوع ویژگی‌های استخراج‌شده تأثیر مستقیمی بر دقت و عملکرد مدل نهایی دارند.

در این پروژه، علاوه بر ویژگی‌های استخراج‌شده از متن نظرات، از اطلاعات موجود در مجموعه داده محصولات و نظرات نیز استفاده شد تا مدل بتواند با در نظر گرفتن عوامل مختلف، تصمیم دقیق‌تری در تشخیص احساسات کاربران اتخاذ کند. ویژگی‌های استخراج‌شده در هفت گروه اصلی طبقه‌بندی شده‌اند.

۱.۶ ویژگی‌های متنی (Text Features)

ویژگی‌های متنی از خود متن نظرات استخراج شدند و اطلاعاتی درباره ساختار و اندازه متن در اختیار مدل قرار دادند. این ویژگی‌ها شامل تعداد کاراکترهای متن، تعداد کلمات، میانگین طول کلمات و سایر شاخص‌های آماری مرتبط با متن هستند. علاوه بر این، متن‌های پیش‌پردازش‌شده با استفاده از روش TF-IDF به بردارهای عددی تبدیل شدند تا الگوریتم‌های یادگیری ماشین بتوانند آن‌ها را پردازش کنند. این دسته از ویژگی‌ها مهم‌ترین منبع اطلاعات برای تشخیص احساس موجود در هر نظر محسوب می‌شوند.

۲.۶ ویژگی‌های امتیازدهی (Rating Features)

امتیاز ثبت‌شده توسط کاربران یکی از مهم‌ترین شاخص‌های تعیین احساس است. در این پروژه، علاوه بر استفاده از امتیاز هر نظر، اختلاف امتیاز ثبت‌شده با میانگین امتیاز همان محصول نیز به‌عنوان یک ویژگی استخراج شد. این ویژگی می‌تواند رفتار غیرمعمول کاربران و میزان اختلاف نظر آن‌ها با سایر خریداران را مشخص کرده و در بهبود عملکرد مدل مؤثر باشد.

۳.۶ ویژگی‌های پیشنهاد خرید (Recommendation Features)

در دیجی‌کالا کاربران می‌توانند پس از ثبت نظر، محصول را به سایر افراد پیشنهاد دهند یا عدم پیشنهاد خود را اعلام کنند. این اطلاعات به‌صورت ویژگی دودویی (Binary Feature) به مدل اضافه شدند. وجود این ویژگی ارتباط مستقیمی با احساس کاربران نسبت به محصول داشته و یکی از عوامل مؤثر در افزایش دقت مدل محسوب می‌شود.

۴.۶ ویژگی‌های وضعیت خریدار (Buyer Features)

در مجموعه داده، مشخص شده است که آیا ثبت‌کننده نظر، خریدار واقعی محصول بوده است یا خیر. نظرات ثبت‌شده توسط خریداران واقعی معمولاً اعتبار بیشتری دارند و بیانگر تجربه عملی استفاده از محصول هستند. بنابراین این ویژگی نیز به‌صورت یک متغیر دودویی در فرآیند آموزش مدل مورد استفاده قرار گرفت.

۵.۶ ویژگی‌های قیمت (Price Features)

اطلاعات مربوط به قیمت محصولات نیز در فرآیند استخراج ویژگی مورد استفاده قرار گرفت. ویژگی‌هایی مانند قیمت نهایی محصول، میزان تخفیف و وضعیت موجودی کالا استخراج شدند. این اطلاعات می‌توانند در تحلیل رفتار کاربران مؤثر باشند؛ زیرا میزان رضایت مشتریان در بسیاری از موارد تحت تأثیر قیمت و ارزش خرید محصول قرار دارد.

۶.۶ ویژگی‌های واکنش کاربران (Reaction Features)

هر نظر در دیجی‌کالا می‌تواند توسط سایر کاربران لایک یا دیسلایک شود. در این پروژه تعداد لایک‌ها، تعداد دیسلایک‌ها و نسبت لایک به کل واکنش‌ها به‌عنوان ویژگی‌های مستقل استخراج شدند. این ویژگی‌ها میزان تأیید یا مخالفت سایر کاربران با هر نظر را نشان داده و می‌توانند به تشخیص اعتبار و جهت‌گیری احساس موجود در آن کمک کنند.

۷.۶ ویژگی‌های زمانی (Temporal Features)

زمان ثبت هر نظر نیز به‌عنوان یکی از منابع اطلاعاتی مورد استفاده قرار گرفت. با استخراج اطلاعاتی مانند روز، ماه و فصل از تاریخ ثبت نظرات (بر اساس تقویم جلالی)، ویژگی‌های زمانی ایجاد شدند. این ویژگی‌ها امکان بررسی تغییرات احساس کاربران در بازه‌های زمانی مختلف و تحلیل الگوهای رفتاری را فراهم می‌کنند.

در پایان این مرحله، تمامی ویژگی‌های استخراج‌شده در کنار بردارهای متنی حاصل از TF-IDF به‌عنوان ورودی مدل‌های یادگیری ماشین مورد استفاده قرار گرفتند. ترکیب ویژگی‌های متنی با اطلاعات جانبی محصولات و کاربران باعث شد مدل علاوه بر محتوای متن، عوامل مؤثر دیگر را نیز در فرآیند تصمیم‌گیری در نظر بگیرد و در نتیجه عملکرد دقیق‌تر و قابل‌اعتمادتری ارائه دهد.

جدول ۲: دسته‌بندی ویژگی‌های استخراج شده

گروه ویژگی	نمونه ویژگی‌ها
ویژگی‌های متنی	تعداد کلمات، تعداد کاراکترها، TF-IDF
ویژگی‌های امتیاز	Rating، اختلاف با میانگین امتیاز محصول
پیشنهاد خرید	پیشنهاد می‌کنم، پیشنهاد نمی‌کنم
وضعیت خریدار	خریدار واقعی یا کاربر عادی
ویژگی‌های قیمت	قیمت محصول، درصد تخفیف، وضعیت موجودی
واکنش کاربران	تعداد لایک، تعداد دیسلایک، نسبت لایک به دیسلایک
ویژگی‌های زمانی	روز ثبت نظر، ماه، فصل

۷ آموزش مدل‌های یادگیری ماشین

پس از تکمیل مراحل پیش‌پردازش و استخراج ویژگی‌ها، داده‌های آماده‌شده برای آموزش مدل‌های یادگیری ماشین مورد استفاده قرار گرفتند. هدف این مرحله، بررسی عملکرد الگوریتم‌های مختلف در طبقه‌بندی احساسات نظرات کاربران و انتخاب مناسب‌ترین مدل برای استفاده در سامانه نهایی بود. با توجه به ماهیت داده‌ها که شامل متون فارسی تبدیل‌شده به بردارهای TF-IDF با ابعاد بالا هستند، سه الگوریتم پرکاربرد و شناخته‌شده در حوزه طبقه‌بندی متن انتخاب شدند. عملکرد هر مدل بر اساس معیارهایی مانند دقت (Accuracy)، دقت کلاس‌ها (Precision)، بازخوانی (Recall) و امتیاز F_1 مورد ارزیابی و مقایسه قرار گرفت.

۱.۷ مدل Logistic Regression

یکی از ساده‌ترین و در عین حال مؤثرترین الگوریتم‌های طبقه‌بندی است که در بسیاری از مسائل پردازش متن عملکرد قابل قبولی ارائه می‌دهد. این مدل با استفاده از یک تابع لجستیک، احتمال تعلق هر نمونه به کلاس‌های مختلف را محاسبه کرده و بر اساس بیشترین احتمال، کلاس نهایی را تعیین می‌کند. در این پروژه، از Logistic Regression به‌عنوان یکی از مدل‌های پایه (Baseline) استفاده شد.

تا عملکرد آن با سایر الگوریتم‌ها مقایسه شود. این مدل به دلیل سرعت مناسب، سادگی پیاده‌سازی و عملکرد مطلوب روی داده‌های با ابعاد بالا، گزینه مناسبی برای تحلیل احساسات متنی محسوب می‌شود.

مزایا:

- سرعت بالای آموزش و پیش‌بینی
- عملکرد مناسب روی داده‌های متنی مبتنی بر TF-IDF
- سادگی پیاده‌سازی و تفسیر نتایج
- مصرف نسبتاً کم منابع پردازشی

معایب:

- توانایی محدود در مدل‌سازی روابط پیچیده بین ویژگی‌ها
- حساسیت به تنظیم پارامترها و توزیع داده‌ها
- کاهش عملکرد در داده‌های بسیار نامتوازن

۲.۷ مدل Linear Support Vector Machine (Linear SVM)

الگوریتم Linear Support Vector Machine (LinearSVC) یکی از موفق‌ترین روش‌های طبقه‌بندی متن در حوزه پردازش زبان طبیعی است. این الگوریتم تلاش می‌کند با یافتن بهترین ابرصفحه (Hyperplane)، بیشترین فاصله ممکن را میان کلاس‌های مختلف ایجاد کرده و مرز تصمیم‌گیری مناسبی برای طبقه‌بندی داده‌ها به دست آورد.

دلیل اصلی انتخاب این مدل، عملکرد بسیار مناسب آن روی داده‌های متنی با ابعاد بالا و بردارهای TF-IDF است. در بسیاری از مسائل طبقه‌بندی متن، LinearSVM نسبت به سایر الگوریتم‌های کلاسیک دقت بیشتری ارائه می‌دهد و به همین دلیل یکی از گزینه‌های اصلی این پروژه محسوب می‌شد.

مزایا:

- دقت بالا در طبقه‌بندی داده‌های متنی
- عملکرد مناسب در داده‌های با تعداد ویژگی زیاد

- مقاومت مناسب در برابر بیش‌برازش (Overfitting)

- سرعت مناسب در فرآیند پیش‌بینی

معایب:

- نیاز به تنظیم مناسب ابرپارامترها

- عدم ارائه احتمال کلاس‌ها به‌صورت مستقیم

- کاهش کارایی در مسائل غیرخطی بدون استفاده از Kernel

نتایج ارزیابی نشان داد که این مدل بهترین عملکرد را در میان مدل‌های بررسی‌شده داشته و پس از بهینه‌سازی نیز به‌عنوان مدل نهایی سامانه انتخاب شد.

۳.۷ مدل Random Forest

یک الگوریتم مبتنی بر مجموعه‌ای از درخت‌های تصمیم (Decision Trees) است که با ترکیب نتایج چندین درخت، تصمیم نهایی را اتخاذ می‌کند. این روش معمولاً در مسائل طبقه‌بندی و رگرسیون عملکرد قابل قبولی داشته و نسبت به یک درخت تصمیم منفرد، پایداری بیشتری دارد.

در این پروژه، Random Forest به‌عنوان یکی از مدل‌های مقایسه‌ای مورد استفاده قرار گرفت تا عملکرد آن در کنار سایر الگوریتم‌ها بررسی شود. اگرچه این مدل در بسیاری از مسائل ساختاریافته نتایج بسیار خوبی ارائه می‌دهد، اما در داده‌های متنی با تعداد ویژگی بسیار زیاد، معمولاً نسبت به الگوریتم‌هایی مانند LinearSVM عملکرد ضعیف‌تری دارد.

مزایا:

- مقاومت مناسب در برابر بیش‌برازش

- توانایی مدل‌سازی روابط غیرخطی

- عدم حساسیت زیاد به داده‌های نویزی

- قابلیت بررسی اهمیت ویژگی‌ها (Feature Importance)

معایب:

- مصرف حافظه و زمان آموزش بیشتر نسبت به مدل‌های خطی
- کاهش کارایی در داده‌های متنی با ابعاد بسیار بالا
- پیچیدگی بیشتر در مقایسه با مدل‌های خطی


۴.۷ مقایسه اولیه مدل‌ها

پس از آموزش هر سه الگوریتم، عملکرد آن‌ها روی دیتاست آزمون مورد ارزیابی قرار گرفت. نتایج نشان داد که هر سه مدل عملکرد قابل قبولی در طبقه‌بندی احساسات داشتند، اما مدل LinearSVM توانست بهترین توازن را میان دقت، سرعت و توانایی تعمیم به داده‌های جدید ارائه دهد. به همین دلیل، این مدل برای مرحله بهینه‌سازی انتخاب شد تا با استفاده از تکنیک‌هایی مانند تنظیم ابرپارامترها و بهبود ویژگی‌ها، عملکرد آن بیش از پیش افزایش یابد.

جدول مقایسه نتایج اولیه مدل‌ها در فصل بعد ارائه شده و فرآیند بهینه‌سازی مدل منتخب به صورت کامل مورد بررسی قرار خواهد گرفت.

جدول ۳: مقایسه دقت مدل‌های یادگیری ماشین

Model	Accuracy
Logistic Regression	65.2%
Linear SVM	72.3%
Random Forest	68.6%



شکل ۲: مقایسه دقت مدل‌ها یادگیری ماشین در تست و یادگیری

بر اساس نتایج اولیه، مدل *LinearSVM* بهترین عملکرد را در بین مدل‌های مورد بررسی داشت و برای مرحله بهینه‌سازی انتخاب شد.

۸ بهبود مدل (Model Improvement)

پس از ارزیابی اولیه مدل‌های یادگیری ماشین، مشخص شد که اگرچه نتایج به دست آمده قابل قبول هستند، اما هنوز امکان افزایش دقت و بهبود توانایی مدل در تشخیص احساسات وجود دارد. به همین دلیل، مجموعه‌ای از روش‌های بهینه‌سازی بر روی مدل‌ها اعمال شد تا علاوه بر افزایش دقت، تعادل بهتری میان کلاس‌های مختلف برقرار شود. در این مرحله، از روش‌هایی مانند بهینه‌سازی بردارسازی متن، تنظیم ابرپارامترها، متعادل‌سازی داده‌ها و ترکیب مدل‌ها استفاده شد.

۱.۸ بهینه‌سازی ویژگی‌های متنی با TF-IDF

یکی از عوامل مؤثر در عملکرد مدل‌های طبقه‌بندی متن، نحوه نمایش داده‌های متنی به صورت بردارهای عددی است. در این پروژه، از روش TF-IDF (Term Frequency-Inverse Document Frequency)

برای تبدیل متن به بردارهای عددی استفاده شد. این روش با در نظر گرفتن میزان تکرار هر واژه در یک متن و میزان اهمیت آن در کل مجموعه داده، وزن مناسبی به کلمات اختصاص می‌دهد. برای افزایش کیفیت ویژگی‌های استخراج شده، پارامترهای TF-IDF مورد بررسی و بهینه‌سازی قرار گرفتند. مهم‌ترین تنظیمات اعمال شده عبارت بودند از:

- استفاده از Unigram ، Bigram و Trigram (ngram range=(1,3))
 - محدود کردن تعداد ویژگی‌ها به ۸۰۰۰ ویژگی
 - حذف کلمات بسیار نادر و بسیار پرتکرار
 - استفاده از Sublinear TF برای کاهش تأثیر کلمات با فراوانی بسیار زیاد
- این تنظیمات باعث شدند نمایش عددی متن‌ها اطلاعات بیشتری از ساختار جملات و ترکیب واژه‌ها را در اختیار مدل قرار دهد.

۲.۸ تنظیم ابرپارامترها با GridSearchCV

هر الگوریتم یادگیری ماشین دارای مجموعه‌ای از پارامترهای قابل تنظیم است که انتخاب مناسب آن‌ها تأثیر مستقیمی بر عملکرد مدل دارد. برای یافتن بهترین ترکیب این پارامترها، از روش GridSearchCV استفاده شد.

در این روش، ترکیب‌های مختلفی از مقادیر پارامترها به صورت خودکار آزمایش شده و عملکرد هر ترکیب با استفاده از اعتبارسنجی متقابل (Cross Validation) ارزیابی گردید. برای مدل LinearSVC پارامترهایی مانند مقدار C و Class Weight بررسی شدند و در نهایت ترکیب زیر بهترین نتیجه را ارائه داد:

$$C = 0.1$$

$$\text{Class Weight} = \text{Balanced}$$

استفاده از این مقادیر باعث افزایش توانایی مدل در تفکیک کلاس‌های مختلف، به ویژه کلاس‌های کم‌تعداد، شد.

۳.۸ متعادل سازی داده ها با SMOTE

یکی از چالش های این پروژه، نامتوازن بودن توزیع کلاس ها بود؛ به طوری که تعداد نظرات مثبت به مراتب بیشتر از نظرات منفی و خنثی بود. این موضوع می تواند باعث شود مدل تمایل بیشتری به پیش بینی کلاس غالب داشته باشد.

برای کاهش این مشکل، از الگوریتم (SMOTE (Synthetic Minority Oversampling Technique استفاده شد. این روش با تولید نمونه های مصنوعی برای کلاس های کم تعداد، تلاش می کند تعادل بهتری میان کلاس ها ایجاد کند.

اگرچه استفاده از SMOTE موجب متوازن تر شدن داده ها شد، اما در آزمایش های انجام شده، دقت نهایی مدل نسبت به نسخه بهینه شده بدون SMOTE کاهش یافت. بنابراین، این روش به عنوان مدل نهایی انتخاب نشد.

۴.۸ استفاده از Voting Ensemble

به منظور بررسی امکان افزایش عملکرد سیستم، از روش Voting Ensemble نیز استفاده شد. در این روش، خروجی سه مدل Logistic Regression ، Random Forest و LinearSVM با یکدیگر ترکیب شد و تصمیم نهایی بر اساس رأی گیری بین مدل ها اتخاذ گردید.

هدف از این روش، بهره گیری از نقاط قوت هر مدل و کاهش خطاهای احتمالی بود. هرچند مدل Ensemble نسبت به برخی مدل های منفرد عملکرد بهتری داشت، اما همچنان نتوانست از مدل بهینه شده LinearSVC پیشی بگیرد.

۵.۸ انتخاب مدل نهایی


پس از انجام تمامی مراحل بهینه سازی، عملکرد روش های مختلف با یکدیگر مقایسه شد. نتایج نشان داد که مدل LinearSVC پس از تنظیم ابرپارامترها و بهینه سازی TF-IDF ، بهترین عملکرد را در میان تمامی روش های بررسی شده ارائه می دهد.

این مدل توانست به دقت حدود ۷۹/۴۵ درصد و مقدار Macro F1 برابر با ۰/۶۳۴ دست یابد که نسبت به نسخه اولیه و سایر روش های آزمایش شده بهبود محسوسی را نشان می دهد. علاوه بر دقت بالاتر، سرعت مناسب در آموزش و پیش بینی، مصرف کمتر منابع پردازشی و عملکرد مطلوب در داده های

متنی با ابعاد بالا از دیگر دلایل انتخاب این مدل به عنوان مدل نهایی سامانه بودند.
 بر همین اساس، مدل بهینه شده LinearSVC ذخیره شده و در بخش Backend برای انجام
 پیش بینی احساسات کاربران مورد استفاده قرار گرفت.

جدول ۴: مقایسه روش های بهبود مدل

Method	Accuracy	Macro F1
Baseline	76.09%	0.606
GridSearch + TF-IDF	79.45%	0.634
SMOTE	73.77%	0.601
Voting Ensemble	78.71%	0.630



شکل ۳: آمار کلی روش های بهبود مدل

۹ نتایج و ارزیابی مدل

پس از آموزش مدل‌های یادگیری ماشین و اعمال روش‌های مختلف بهینه‌سازی، عملکرد آن‌ها بر روی دیتاست تست مورد ارزیابی قرار گرفت. برای سنجش کیفیت مدل‌ها، از معیارهای متداول ارزیابی در مسائل طبقه‌بندی شامل Accuracy، Precision، Recall و Macro F1-Score استفاده شد. همچنین، به منظور تحلیل دقیق‌تر نحوه عملکرد مدل در تشخیص هر کلاس، ماتریس درهم‌ریختگی (Confusion Matrix) نیز مورد بررسی قرار گرفت.

۱.۹ نتایج دقت (Accuracy)

جدول ۴ عملکرد روش‌های مختلف را از نظر دقت (Accuracy) نشان می‌دهد. همان‌طور که مشاهده می‌شود، استفاده از روش‌های بهینه‌سازی موجب افزایش قابل توجه دقت مدل نسبت به نسخه اولیه شده است.

نتایج نشان می‌دهد که استفاده از GridSearchCV در کنار تنظیم پارامترهای TF-IDF بیشترین تأثیر را در افزایش دقت مدل داشته و توانسته است عملکرد سیستم را نسبت به مدل اولیه حدود ۳ درصد بهبود دهد.

۲.۹ نتایج معیار F1-Score

از آنجا که توزیع کلاس‌های احساسات کاملاً متوازن نیست، تنها استفاده از معیار Accuracy برای ارزیابی مدل کافی نیست. به همین دلیل، از معیار Macro F1-Score نیز استفاده شد تا عملکرد مدل در تمامی کلاس‌ها به صورت یکسان مورد بررسی قرار گیرد.


جدول ۵: مقایسه روش‌های مختلف بر اساس معیار Macro F۱

Method	Macro F1
Baseline	0.606
GridSearch + TF-IDF	0.634
SMOTE	0.601
Voting Ensemble	0.630

همان‌طور که مشاهده می‌شود، مدل بهینه‌شده LinearSVC علاوه بر دستیابی به بیشترین Accuracy، بالاترین مقدار Macro F1 را نیز کسب کرده است که نشان‌دهنده عملکرد مناسب‌تر آن در طبقه‌بندی هر سه کلاس احساسات است.

۳.۹ ماتریس درهم‌ریختگی (Confusion Matrix)

برای تحلیل دقیق‌تر عملکرد مدل، از ماتریس درهم‌ریختگی (Confusion Matrix) استفاده شد. این ماتریس تعداد پیش‌بینی‌های صحیح و نادرست مدل را برای هر کلاس نمایش می‌دهد و مشخص می‌کند که مدل در تشخیص کدام کلاس‌ها عملکرد بهتری داشته و در کدام بخش‌ها دچار خطا شده است.



شکل ۴: ماتریس درهم‌ریختگی مدل نهایی (LinearSVC)

بررسی ماتریس درهم‌ریختگی نشان می‌دهد که مدل در تشخیص نظرات مثبت عملکرد بسیار مطلوبی داشته و بیشتر نمونه‌های این کلاس را به‌درستی شناسایی کرده است. در مقابل، بیشترین میزان خطا مربوط به کلاس خنثی است؛ زیرا این دسته از نظرات معمولاً دارای ویژگی‌هایی مشترک با نظرات مثبت و منفی بوده و مرز مشخصی میان آن‌ها وجود ندارد. همچنین، بخش قابل توجهی از نمونه‌های کلاس منفی نیز به‌درستی شناسایی شده‌اند که نشان‌دهنده توانایی مناسب مدل در تشخیص احساسات منفی کاربران است.

۴.۹ تحلیل نتایج

نتایج به دست آمده نشان می‌دهد که استفاده از مراحل دقیق پیش‌پردازش، استخراج ویژگی‌های مناسب و بهینه‌سازی مدل تأثیر قابل توجهی بر افزایش عملکرد سیستم داشته است. مدل LinearSVC پس از تنظیم ابرپارامترها و بهینه‌سازی بردارسازی TF-IDF، توانست بهترین نتایج را در میان تمامی روش‌های بررسی شده به دست آورد.

از سوی دیگر، آزمایش روش SMOTE نشان داد که اگرچه این تکنیک موجب متعادل‌تر شدن داده‌ها می‌شود، اما در این پروژه نتوانست عملکرد کلی مدل را بهبود دهد. همچنین، استفاده از Voting Ensemble نسبت به مدل پایه نتایج بهتری ارائه کرد، اما همچنان اندکی ضعیف‌تر از مدل بهینه شده LinearSVC بود.

به طور کلی، نتایج ارزیابی نشان می‌دهد که مدل نهایی قادر است با دقت قابل قبول، احساس موجود در نظرات فارسی کاربران را تشخیص دهد و از این رو برای استفاده در سامانه تحلیل احساسات توسعه یافته مناسب است. با این حال، عملکرد پایین‌تر مدل در کلاس خنثی نشان می‌دهد که هنوز ظرفیت بهبود وجود دارد و استفاده از مدل‌های مبتنی بر یادگیری عمیق مانند ParsBERT می‌تواند در آینده موجب افزایش دقت و بهبود تشخیص این دسته از نظرات شود.

۱۰ طراحی و پیاده‌سازی Backend

بخش Backend این پروژه با استفاده از فریم‌ورک FastAPI توسعه داده شده است و وظیفه مدیریت درخواست‌های کاربران، اجرای مدل یادگیری ماشین، برقراری ارتباط با پایگاه داده و ارائه اطلاعات مورد نیاز به رابط کاربری را بر عهده دارد. طراحی این بخش به صورت ماژولار انجام شده است تا هر قسمت از سیستم مسئولیت مشخصی داشته باشد و توسعه یا نگهداری آن در آینده با سهولت بیشتری انجام شود.

معماری Backend به گونه‌ای طراحی شده است که پس از دریافت درخواست از کاربر، ابتدا داده‌های ورودی اعتبارسنجی شده، سپس عملیات پیش‌پردازش متن و پیش‌بینی احساس توسط مدل یادگیری ماشین انجام می‌شود. در ادامه، نتیجه در صورت نیاز در پایگاه داده ذخیره شده و پاسخ مناسب به کاربر بازگردانده می‌شود. این ساختار علاوه بر سادگی، امکان توسعه قابلیت‌های جدید بدون ایجاد تغییرات اساسی در سایر بخش‌های سیستم را فراهم می‌کند.

۱.۱۰ استفاده از FastAPI

برای توسعه API های پروژه از FastAPI استفاده شده است. FastAPI یکی از فریم‌ورک‌های مدرن زبان Python برای توسعه API REST محسوب می‌شود. از دیگر مزایای FastAPI می‌توان به سادگی توسعه Endpoint های جدید، عملکرد مناسب در پردازش هم‌زمان درخواست‌ها و سازگاری کامل با کتابخانه‌های یادگیری ماشین اشاره کرد.

۲.۱۰ ساختار Route ها

به منظور افزایش خوانایی و قابلیت نگهداری پروژه، Endpoint های سیستم در قالب چند Route مستقل سازمان‌دهی شده‌اند که هرکدام مسئول بخشی از عملکرد سامانه هستند.

- بخش تحلیل احساسات (Sentiment): این بخش وظیفه دریافت متن نظرات کاربران، اجرای مدل یادگیری ماشین و بازگرداندن نتیجه تحلیل احساسات را بر عهده دارد. علاوه بر پیش‌بینی یک نظر، امکان تحلیل هم‌زمان چندین نظر نیز در این قسمت پیاده‌سازی شده است.
- بخش تاریخچه (History): تمامی پیش‌بینی‌هایی که از طریق سرویس تحلیل تک‌نظر انجام می‌شوند، در پایگاه داده ذخیره می‌شوند. این بخش امکان مشاهده تاریخچه تحلیل‌ها، دریافت آمار کلی احساسات، مشاهده جزئیات هر رکورد و حذف اطلاعات ذخیره‌شده را فراهم می‌کند.
- بخش محصولات (Products): این Route اطلاعات مربوط به محصولات را در اختیار کاربران قرار می‌دهد. کاربران می‌توانند محصولات را جستجو کرده، اطلاعات مربوط به هر محصول را مشاهده کنند و علاوه بر آن، خلاصه‌ای از نظرات کاربران و توزیع احساسات ثبت‌شده برای آن محصول را دریافت نمایند.

۳.۱۰ پایگاه داده

برای ذخیره اطلاعات از پایگاه داده SQLite استفاده شده است. ارتباط برنامه با پایگاه داده نیز توسط SQLAlchemy ORM و به صورت Asynchronous مدیریت می‌شود. در این پروژه دو جدول اصلی در پایگاه داده وجود دارد:

۱. Prediction History: ذخیره متن ورودی کاربران، متن پیش‌پردازش شده، نتیجه تحلیل احساسات، میزان اطمینان مدل و زمان ثبت درخواست.

۲. Product Summaries: ذخیره خلاصه تحلیل محصولات و نتایج محاسبه شده به منظور جلوگیری از پردازش مجدد درخواست‌های بعدی.

استفاده از مکانیزم Cache برای اطلاعات محصولات باعث کاهش زمان پاسخ‌گویی سیستم و جلوگیری از انجام محاسبات تکراری شده است.

۴.۱۰ فرآیند پیش‌بینی احساسات (Prediction Flow)

فرآیند تحلیل احساسات در Backend شامل چند مرحله متوالی است. ابتدا متن ارسال شده توسط کاربر اعتبارسنجی شده و سپس همان مراحل پیش‌پردازش که در زمان آموزش مدل استفاده شده بودند، بر روی متن اعمال می‌شوند. در ادامه، متن پیش‌پردازش شده توسط بردار ساز TF-IDF به نمایش عددی تبدیل شده و به مدل آموزش دیده LinearSVC ارسال می‌شود.

پس از انجام پیش‌بینی، برچسب احساس (مثبت، منفی یا خنثی) تعیین شده و با استفاده از مقدار Decision Function مدل، یک مقدار Confidence نیز محاسبه می‌شود تا میزان اطمینان مدل نسبت به پیش‌بینی مشخص گردد. در نهایت، نتیجه برای کاربر ارسال شده و در صورت تحلیل تک نظر، اطلاعات در جدول تاریخچه نیز ذخیره می‌شود.

۵.۱۰ مدیریت تاریخچه تحلیل‌ها

هر بار که کاربر متنی را برای تحلیل ارسال می‌کند، اطلاعات مربوط به آن درخواست شامل متن اصلی، متن پیش‌پردازش شده، نتیجه تحلیل، میزان اطمینان مدل و زمان ثبت در پایگاه داده ذخیره می‌شود. این قابلیت علاوه بر امکان مشاهده سوابق تحلیل، امکان تهیه آمار کلی از تعداد نظرات مثبت، منفی و خنثی و همچنین حذف یا بازیابی اطلاعات ذخیره شده را نیز فراهم می‌کند.


۶.۱۰ خلاصه‌سازی نظرات محصولات (Product Summary)

یکی از قابلیت‌های کاربردی این پروژه، تولید خلاصه‌ای از مهم‌ترین نظرات کاربران درباره هر محصول است. هدف از این بخش، کاهش زمان موردنیاز برای مطالعه تعداد زیادی نظر و ارائه دیدگاهی کلی از نقاط قوت، نقاط ضعف و تجربه کاربران نسبت به یک محصول است.

در این پروژه، برای تولید خلاصه از مدل زبانی Qwen3 (Large Language Model) استفاده شده است. پس از دریافت درخواست کاربر، تمامی نظرات مربوط به محصول موردنظر جمع‌آوری شده و پس از انجام مراحل لازم برای آماده‌سازی متن، به مدل Qwen3 ارسال می‌شوند. این مدل با درک معنایی نظرات، مهم‌ترین اطلاعات موجود در میان دیدگاه‌های کاربران را استخراج کرده و خلاصه‌ای روان، منسجم و قابل فهم تولید می‌کند.

استفاده از مدل Qwen3 این امکان را فراهم می‌کند که خلاصه تولیدشده صرفاً بر اساس فراوانی کلمات نباشد، بلکه مفهوم کلی نظرات نیز در نظر گرفته شود. در نتیجه، مدل می‌تواند نقاط قوت و ضعف تکرارشونده، موضوعات پرتکرار و دیدگاه کلی کاربران نسبت به محصول را به صورت یک متن طبیعی و خوانا ارائه دهد. این ویژگی باعث می‌شود کیفیت خلاصه‌های تولیدشده نسبت به روش‌های کلاسیک استخراجی به طور قابل توجهی افزایش یابد.

به منظور کاهش زمان پاسخ‌گویی و جلوگیری از اجرای مجدد مدل زبانی برای درخواست‌های تکراری، خلاصه تولیدشده تنها در اولین درخواست مربوط به هر محصول ایجاد شده و در جدول Product Summaries پایگاه داده ذخیره می‌شود. در درخواست‌های بعدی، خلاصه مستقیماً از پایگاه داده بازیابی شده و بدون نیاز به فراخوانی مجدد مدل، در اختیار کاربر قرار می‌گیرد. این مکانیزم کش (Caching) علاوه بر کاهش مصرف منابع محاسباتی، موجب افزایش سرعت پاسخ API و بهبود تجربه کاربری می‌شود.



شکل ۵: معماری بخش Backend و جریان پردازش درخواست‌ها

۱۱ طراحی و پیاده‌سازی Frontend

رابط کاربری (Frontend) این پروژه با استفاده از کتابخانه React و زبان TypeScript توسعه داده شده است. هدف از طراحی این بخش، ایجاد محیطی ساده، سریع و کاربرپسند برای برقراری ارتباط کاربران با سامانه تحلیل احساسات بوده است. کاربران از طریق این رابط می‌توانند محصولات را جستجو کنند، احساس نظرات را تحلیل نمایند، اطلاعات هر محصول را مشاهده کرده و نتایج پردازش مدل یادگیری ماشین را به صورت گرافیکی دریافت کنند.

در طراحی Frontend تلاش شده است تا علاوه بر زیبایی ظاهری، سرعت عملکرد، قابلیت توسعه و تجربه کاربری مناسب نیز در نظر گرفته شود. همچنین تمامی ارتباطات با Backend از طریق REST API انجام شده و تمامی داده‌های نمایش داده‌شده در صفحات، به‌صورت پویا از سرور دریافت می‌شوند.


۱.۱۱ معماری Frontend

معماری پروژه بر اساس ساختار Component-Based در React طراحی شده است. در این معماری، رابط کاربری به مجموعه‌ای از کامپوننت‌های مستقل تقسیم شده است که هرکدام مسئول انجام وظیفه مشخصی هستند. این ساختار باعث افزایش خوانایی کد، قابلیت استفاده مجدد از کامپوننت‌ها و سهولت نگهداری پروژه می‌شود.

هر صفحه از سیستم از ترکیب چندین کامپوننت کوچک‌تر تشکیل شده است و تنها مسئول مدیریت منطق همان صفحه می‌باشد. همچنین ارتباط با Backend از طریق لایه مجزایی برای ارسال درخواست‌های HTTP انجام می‌شود که باعث کاهش وابستگی بین بخش‌های مختلف پروژه شده است.

۲.۱۱ صفحات سیستم

برای استفاده بهتر کاربران، رابط کاربری پروژه در قالب چند صفحه اصلی طراحی شده است. در ادامه تصاویری از بخش‌های رابط کاربری مشاهده می‌کنید:



شکل ۶: صفحه اصلی وب اپلیکیشن


این صفحه اولین بخشی است که کاربر پس از ورود به سامانه مشاهده می‌کند. در این صفحه معرفی کوتاهی از پروژه، امکانات سامانه و راه‌های دسترسی به بخش‌های مختلف سیستم نمایش داده می‌شود.



شکل ۷: صفحه تحلیل احساسات (مثبت)




شکل ۸: صفحه تحلیل احساسات (منفی)



شکل ۹: صفحه تحلیل احساسات (خنثی)

در این صفحه کاربر می‌تواند متن یک نظر را وارد کرده و پس از ارسال، نتیجه تحلیل احساسات را مشاهده کند. پس از دریافت پاسخ از Backend، نوع احساس (مثبت، منفی یا خنثی)، میزان اطمینان مدل (Confidence) و سایر اطلاعات مرتبط به کاربر نمایش داده می‌شود.



شکل ۱۰: صفحه جستجوی محصولات

این صفحه امکان جستجوی محصولات را بر اساس نام، برند یا دسته‌بندی فراهم می‌کند. نتایج جستجو به‌صورت پویا از Backend دریافت شده و کاربران می‌توانند محصول موردنظر خود را انتخاب کنند.

عزت

کرم دکلره دنی وان مدل D5 وزن 120 گرم

آراییش مو متفرقه

۳.۵      ۷.۸ نظر

عزت

خشکی

منفی

(۵) 65%

(۱۵) 19%

(۱۲) 15%

خلاصه نظرات

موش مصنوعی

بیشتر کاربران از کیفیت و تأثیر مطلوب محصول راضی هستند، اما برخی به دلیل نیاز به زمان بیشتر یا قدرت رنگبری کمتر نظرات متوسطی دارند.

نقاط قوت

- کیفیت خوب
- عدم آسیب به مو
- رنگ طبیعی و پوشاننده
- جواب‌دهی مطلوب در بلندمدت

نقاط ضعف

- قدرت رنگبری محدود
- نیاز به زمان و حوصله بیشتر
- عدم رسیدن به پایه‌های پایین‌تر رنگ

خلاصه توسط هوش مصنوعی از نظرات کاربران تولید شده است

نظرات کاربران

همه مثبت خنثی منفی

- عزت

۲۵ شهریور ۱۴۰۲     

خوبه فقط زیاد قدرت نداره ولی خوب آسیب نمیزنه به مو
- عزت

۲۳ شهریور ۱۴۰۲     

راضی بودم
- عزت

۱۹ مرداد ۱۴۰۲     

خوبه من راضی بودم
- عزت

۱۸ خرداد ۱۴۰۲     

هنوز استفاده نکردم استفاده ک کردم نظرم رو میدارم ولی چون دوستان تعریف کرده بودن ازش منم خریدم
- عزت

۱۶ خرداد ۱۴۰۲     

این محصول روی مو جواب دهی خوبی داشته
- عزت

۲۴ اسفند ۱۴۰۱     

موهای ضخیم و مشکلی ام رو به پایه ۱۰ رسوندم کاملا سفید شد فقط نیاز به نایم و حوصله زیاد داره
- خنثی

۳ دی ۱۴۰۱     

کیفیت خوبی داره
- عزت

۲۳ آذر ۱۴۰۱     

من برای بدن استفاده کردم عالی بود رنگ طبیعی میده چوری که اصلا دیگه موها مشخص نمیشع
- خنثی

۸ مهر ۱۴۰۱     

بد نبود کلا که کرم زیاد باز نمیکنه رنگو ولی در حد نارنجی یا دوبار اونکی بود
- عزت

۲۲ مرداد ۱۴۰۱     

به پایه صفر نمرسونه ولی صور باشید ۴۵ دقیقه تقریبا ۸ یا ۹ میشه

قبلی ۸ / ۱ بعدی

آخرین به‌روزرسانی: ۱۴۰۵/۲/۱۵

شکل ۱۱: صفحه جزئیات محصول

پس از انتخاب یک محصول، اطلاعات کامل آن نمایش داده می‌شود. این اطلاعات شامل مشخصات محصول، تعداد نظرات، توزیع احساسات کاربران، خلاصه نظرات تولیدشده توسط سیستم و فهرست نظرات ثبت‌شده برای محصول است. همچنین امکان مشاهده نظرات به صورت صفحه‌بندی‌شده نیز فراهم شده است.

۳.۱۱ ارتباط با Backend

تمامی ارتباطات Frontend با Backend از طریق Axios و سرویس‌های REST API انجام می‌شود. برای هر عملیات، درخواست مناسب به سرور ارسال شده و پس از دریافت پاسخ، اطلاعات موردنیاز در رابط کاربری نمایش داده می‌شود.

از جمله مهم‌ترین درخواست‌های ارسال‌شده می‌توان به موارد زیر اشاره کرد:

- ارسال متن برای تحلیل احساسات

- جستجوی محصولات

- دریافت اطلاعات کامل هر محصول

- دریافت خلاصه نظرات

- دریافت لیست نظرات محصولات

جداسازی منطق ارتباط با سرور در پوشه services باعث شده است که مدیریت API ها ساده‌تر شده و در صورت تغییر Backend، تنها این بخش نیاز به بروزرسانی داشته باشد.

۴.۱۱ مدیریت وضعیت برنامه (State Management)

برای مدیریت داده‌های مشترک میان صفحات مختلف از کتابخانه Zustand استفاده شده است. این کتابخانه نسبت به بسیاری از راهکارهای دیگر حجم کمتری داشته و پیاده‌سازی ساده‌تری ارائه می‌دهد. اطلاعاتی مانند نتایج جستجو، داده‌های محصولات، وضعیت بارگذاری (Loading)، اطلاعات تحلیل احساسات و سایر داده‌های مشترک در Store های برنامه نگهداری می‌شوند تا بدون نیاز به ارسال مکرر درخواست یا انتقال داده بین کامپوننت‌ها، در تمامی بخش‌های موردنیاز قابل استفاده باشند.

۵.۱۱ طراحی رابط کاربری

در طراحی رابط کاربری پروژه از Tailwind CSS استفاده شده است. این فریم‌ورک امکان طراحی سریع، منظم و واکنش‌گرا را فراهم کرده است. در طراحی صفحات، سادگی و تجربه کاربری مناسب در اولویت قرار گرفته است. استفاده از کارت‌های اطلاعاتی (Cards)، دکمه‌های استاندارد، نمایش مناسب وضعیت بارگذاری، چیدمان منظم اطلاعات و طراحی واکنش‌گرا باعث شده است که کاربران بتوانند در دستگاه‌های مختلف از سامانه استفاده کنند.

۱۲ پیشنهادات آینده و دسترسی به کد منبع و مستندات

۱.۱۲ پیشنهادات برای توسعه آینده

با توجه به ساختار ماژولار پروژه، قابلیت‌های متعددی می‌توانند در نسخه‌های آینده به آن اضافه شوند. برخی از مهم‌ترین پیشنهادات عبارت‌اند از:

- استفاده از مدل‌های مبتنی بر Transformer مانند ParsBERT یا XLM-RoBERTa برای افزایش دقت تحلیل احساسات
- آموزش مدل روی کل مجموعه داده شش میلیون نظر کاربران
- استفاده از پایگاه داده PostgreSQL به جای SQLite برای افزایش مقیاس‌پذیری
- استقرار پروژه با استفاده از Docker و طراحی فرآیند CI/CD
- توسعه سیستم پیشنهاد محصول بر اساس تحلیل احساسات کاربران
- افزودن داشبوردهای آماری و نمودارهای تحلیلی برای مدیران
- پیاده‌سازی احراز هویت کاربران و ایجاد حساب کاربری
- توسعه نسخه موبایل یا تبدیل سامانه به یک برنامه Progressive Web App (PWA)

در مجموع، نتایج این پروژه نشان می‌دهد که استفاده از روش‌های یادگیری ماشین در کنار طراحی مناسب نرم‌افزار می‌تواند سامانه‌ای کاربردی و قابل توسعه برای تحلیل احساسات متون فارسی ایجاد کند. همچنین ساختار پیاده‌سازی شده این پروژه، بستر مناسبی برای توسعه قابلیت‌های پیشرفته‌تر در آینده فراهم کرده و می‌تواند به عنوان پایه‌ای برای پروژه‌های پژوهشی و صنعتی در حوزه پردازش زبان طبیعی مورد استفاده قرار گیرد.

۲.۱۲ دسترسی به کد منبع و مستندات

- رپازیتوری گیت‌هاب:

<https://github.com/Aref0rumiehei/digikala-prods-comments-analysis>

- مستندات (API (Swagger):

Digikala Sentiment Analysis API 2.0.0 OpenAPI 3.1	
OpenAPI JSON	
Persian comment sentiment classifier — positive / neutral / negative	
Sentiment	
POST	/sentiment/predict Predict Single
POST	/sentiment/predict-batch Predict Batch
History	
GET	/history Get History
GET	/history/stats Get History Stats
GET	/history/{prediction_id} Get Single Prediction
DELETE	/history/{prediction_id} Delete Prediction
Products	
GET	/products/search Search Products
GET	/products/{product_id} Get Product Summary
GET	/products/{product_id}/comments Get Product Comments
Health	
GET	/ Root
GET	/health Health

شکل ۱۲: مستندات سرویس‌ها